

多模态数据集质量扫描系统初期成果整理报告

PPT 制作版：已完成成果、展示逻辑与下一步计划

项目名称	多模态数据集质量扫描系统
汇报阶段	初期检查/阶段成果汇报
整理日期	2026 年 5 月 10 日
材料用途	直接拆分为 PPT 页面、口头汇报稿和检查表内容

一、汇报主线

建议初期汇报采用“问题背景 → 系统目标 → 已完成平台骨架 → 四引擎算法路线 → 演示流程 → 下一步计划”的结构。当前最稳妥的表达是：系统平台与演示链路已经搭建完成，算法侧已完成调研和接口设计，下一阶段重点是真实算法服务接入。

二、已完成成果

成果模块	已完成内容	汇报时可强调的价值
后端服务骨架	使用 Go + Gin 搭建服务入口、路由分组、配置加载、依赖注入和模块化目录结构。	项目已从想法推进到可运行系统骨架，具备继续扩展算法的工程基础。
数据集管理	完成数据集创建、列表、详情、删除接口，并在前端提供登记入口。	为后续扫描任务提供统一数据对象，避免算法服务各自管理输入。
四类扫描引擎	定义分布偏差、脏数据、对抗脆弱性、物理保真度四类引擎的元信息、支持模态、算法列表和输出字段。	质量维度清晰，覆盖基础质量、分布、鲁棒性和物理一致性。
统一扫描任务	实现 `/api/v1/scan/start`、任务状态、任务结果查询，支持选择全部或部分引擎。	形成统一调度入口，便于后续把多个算法结果汇总到一份报告。
质量报告接口	实现报告查询入口，返回问题统计、图表占位、样本问题列表和建议字段。	PPT 中可以展示报告结构，说明后续算法接入后前端无需重构。
前端演示页面	完成单页 Web 界面，包含数据集、扫描引擎、扫描任务、质量报告四个区域。	可现场演示完整交互流程，让初期成果更直观。
算法服务预留	在 `internal/infra/httpclient/algo_client.go` 中预留 Python 算法服务 HTTP Client，并在配置中保留 `algo_api`。	后端与算法解耦，后续可以由 Python 独立实现算法再接入。

三、PPT 页面建议

页码	页面标题	核心内容	可放视觉元素
1	项目背景：多模态数据集质量不可忽视	数据集质量会影响模型效果、鲁棒性和可信度，传统检查多停留在缺失/重复，难以覆盖多模态质量风险。	问题示例四宫格：分布偏斜、错标、扰动敏感、物理异常。
2	项目目标：构建统一质	面向表格、文本、时序、图像等数据，统一登记、扫描、	系统目标示意图。

初期成果汇报材料

页码	页面标题	核心内容	可放视觉元素
	量扫描系统	汇总和报告展示。	
3	总体架构	前端页面、Go 后端、内存 DAO/任务模型、Python 算法服务预留、质量报告输出。	架构图：Web → API → Scan Service → Engine/Python → Report。
4	四大扫描引擎	分布偏差、脏数据、对抗脆弱性、物理保真度，每个引擎对应质量维度和输出结果。	四象限引擎卡片。
5	当前系统功能	数据集管理、引擎选择、启动扫描、任务查询、报告查看。	前端页面截图或功能流程图。
6	后端接口与数据结构	展示核心 API 和 Result/EngineResult/Report 结构，突出已完成可扩展接口。	接口表格或 JSON 片段。
7	算法论文调研结论	论文支撑四类算法路线：DataComp/CLIPScore、Cleanlab、FGSM/PGD、PhyBench 等。	论文到引擎映射表。
8	下一阶段算法接入路线	先接规则/统计算法，再接标签错误和图文一致性，最后接对抗与物理一致性深度检测。	三阶段路线图。
9	预期成果	形成可运行平台、算法服务、质量报告、演示数据集和阶段论文/报告材料。	成果清单。
10	风险与解决方案	算法依赖模型与数据，优先用可解释规则稳定演示；统一输出结构降低集成风险。	风险-对策表。

四、可直接放入 PPT 的文字

项目简介

本项目面向多模态数据集在分布偏差、脏数据、对抗脆弱性与物理一致性等方面的质量问题，构建统一扫描平台，实现数据集登记、四引擎调度、结果汇总与报告展示，为后续算法接入和质量治理提供工具支撑。

阶段成果一句话

目前已完成多模态数据集质量扫描系统的后端骨架、四类扫描引擎定义、统一扫描任务接口、质量报告结构和前端演示页面，并完成了算法论文调研与 Python 算法服务接入方案设计。

演示讲解顺序

- 1. 打开系统首页，展示数据集登记、引擎选择、任务启动和报告区域。

- 2. 创建示例数据集，说明平台以统一数据对象组织扫描任务。
- 3. 展示四类扫描引擎，解释每个引擎覆盖的质量风险。
- 4. 启动多引擎扫描，展示后端返回的结构化任务结果与报告字段。
- 5. 说明当前结果为占位结构，下一阶段会由 Python 算法服务返回真实检测结果。

五、下一步计划

时间	任务	交付物
2026.5-2026.6	完善文献调研，确定第一批可演示算法；补充测试数据集和接口联调脚本。	算法清单、示例数据、联调说明。
2026.6-2026.8	接入基础规则检测、分布统计、标签错误检测和图像基础质量检测。	Python 算法服务、真实扫描结果。
2026.9-2026.11	完善图文一致性、对抗脆弱性和物理一致性检测；优化报告图表。	多引擎报告、前端可视化。
2026.12-2027.2	进行系统测试、性能优化和典型数据集案例分析。	测试报告、案例报告。
2027.3-2027.4	整理结题材料、演示视频和最终成果文档。	结题报告、PPT、演示材料。