

南京航空航天大学

大学生创新创业训练计划项目初期检查表

项目字段	填写内容
项目名称	多模态数据集质量扫描系统
项目类型	(√) 创新创业训练计划项目 () 主题创新区在研创新训练项目 () 校企平台在研项目
研究起止日期	2026.4—2027.4
管理单位	待补：请填写所在学院/管理单位

项目简介（100 字以内）

本项目面向多模态数据集在分布偏差、脏数据、对抗脆弱性与物理一致性等方面的质量问题，构建统一扫描平台，实现数据集登记、四引擎调度、结果汇总与报告展示。

项目成员

成员	姓名	学号	联系电话	邮箱	主要分工
负责人	待填	待填	待填	待填	总体方案设计、后端架构、汇报材料统筹。
成员 2	待填	待填	待填	待填	算法论文调研、分布偏差与脏数据算法方案。
成员 3	待填	待填	待填	待填	对抗脆弱性与物理保真度算法方案、实验设计。
成员 4	待填	待填	待填	待填	前端页面、可视化报告与交互演示。
成员 5	待填	待填	待填	待填	测试数据整理、系统测试、文档与 PPT 制作。

研究方案

研究目标

- 构建面向表格、文本、时序、图像等多模态数据集的质量扫描系统。
- 形成分布偏差、脏数据、对抗脆弱性、物理保真度四类检测算法方案。
- 实现后端服务、前端展示、统一任务调度与质量报告接口。
- 完成初步算法论文调研，并预留 Python 算法服务接入能力，为后续真实算法落地提供基础。

创新特色概述

- 质量维度更全面：从传统缺失、重复扩展到分布偏差、鲁棒性风险和物理一致性。
- 系统设计可扩展：后端统一调度，算法服务独立接入，便于后续替换或新增检测引擎。
- 面向多模态数据：同时考虑结构化表格、文本、时序和图像数据的质量风险。
- 输出可解释：每类引擎均输出指标、问题类型、样本列表、图表数据和整改建议。

技术路线

具体步骤及可行性

1. 明确多模态数据集质量问题，建立四类质量维度和统一输出结构。
2. 调研 DataComp、CLIPScore、Cleanlab、FGSM/PGD、PhyBench 等相关论文，确定可落地算法。
3. 搭建 Go + Gin 后端，实现数据集管理、扫描任务、四引擎元信息和报告查询接口。
4. 完成浏览器前端页面，支持数据集登记、引擎选择、任务启动和报告查看。
5. 设计 Python 算法服务接口，后续逐步接入统计规则、标签错误检测、图文一致性、对抗与物理一致性检测。
6. 通过示例数据集进行联调测试，生成质量报告并优化可视化展示。

采用技术手段

- 后端：Go、Gin、REST API、YAML 配置、依赖注入、任务模型与内存 DAO。
- 前端：HTML、CSS、JavaScript 单页交互界面。
- 算法：分布统计、规则约束、置信学习、CLIP 图文一致性、FGSM/PGD 对抗探针、物理规则库。
- 接口：通过 HTTP Client 对接 Python 算法服务，统一返回结构化质量报告。

关键性问题及解决方法

关键问题	解决方法
------	------

大学生创新创业训练计划项目初期检查表

关键问题	解决方法
多模态数据差异大，算法输入不统一	先统一任务输入、模态字段和报告结构，再让各算法服务适配不同模态。
初期真实算法接入工作量较大	第一阶段优先接入规则校验和统计类算法，保证可演示；深度算法分阶段接入。
检测结果需要可解释	每个问题样本保留问题类型、风险等级、指标值和整改建议，便于人工复核。
前后端与算法服务耦合风险	采用 Go 后端调度 + Python 算法服务的分层架构，通过 HTTP 接口解耦。

项目分工

负责人负责总体方案、后端架构设计和阶段汇报统筹；算法方向成员负责论文调研、指标体系和 Python 算法服务设计；前端方向成员负责页面交互、报告可视化和演示流程；测试与文档方向成员负责示例数据、接口测试、检查表、报告和 PPT 材料整理。成员姓名、学号和具体岗位可根据实际团队信息替换。

实施条件

项目已具备初步工程基础：已完成 Go 后端骨架、四类扫描引擎元信息、统一扫描任务接口、质量报告结构、算法服务 HTTP Client 预留和前端演示页面。后续可依托现有电脑开发环境、开源算法库、公开数据集和指导教师/学院提供的软硬件条件继续推进。

研究进展

项目计划

时间	计划内容
2026.4-2026.5	完成需求分析、质量维度设计、系统骨架搭建和初期汇报材料。
2026.6-2026.8	接入基础规则检测、分布偏差统计、标签错误检测和图像基础质量算法。
2026.9-2026.11	完善图文一致性、对抗脆弱性和物理保真度检测，优化报告展示。
2026.12-2027.2	开展典型数据集测试、算法效果分析、系统稳定性优化。
2027.3-2027.4	整理结题报告、PPT、演示视频和成果材料。

前期工作进展

- 已整理项目目标，明确四类质量扫描引擎：分布偏差、脏数据、对抗脆弱性、物理保真度。
- 已搭建 Go + Gin 后端工程，完成健康检查、数据集管理、扫描任务、引擎查询和报告查询接口。
- 已完成轻量前端页面，可进行数据集登记、引擎选择、任务启动和报告查看。
- 已预留 Python 算法服务 HTTP Client 和 `algo\_api` 配置，为后续真实算法接入做准备。
- 已完成算法论文初步调研，形成算法路线与平台输出字段映射。
- 当前真实算法尚未接入，系统返回的是结构化占位结果；下一阶段将优先接入规则统计和标签错误检测算法。

指导教师意见：

签字： 日期：

验收专家组结论、学校评审意见：由评审阶段填写。