



南京航空航天大学

NANJING UNIVERSITY OF AERONAUTICS AND ASTRONAUTICS

多模态数据集质量扫描系统

创新创业训练项目 · 初期成果汇报

组长：徐天一

组员：张月晴 马雨萌

指导老师：周宇

目录/Contents



01

项目背景与意义

02

系统目标与总体架构

03

四类质量扫描引擎与算法路线

04

已完成成果与系统演示

05

计划与预期成果（含风险对策）

01



项目背景与意义

多模态数据质量问题已成为模型效果于安全瓶颈，需要系统化扫描平台。



- 多模态数据成为 AI 核心基石，质量直接影响性能/鲁棒性/可信度。
- 传统质检仅覆盖缺失/重复，无法应对多模态风险。
- 分布偏差：类别分布不均、概念覆盖不足。
- 脏数据/标签错误：错标、格式异常、模糊/过曝等。
- 对抗脆弱性：微小扰动导致模型失效。
- 物理保真度：违反物理/业务逻辑。

意义：建立统一质量扫描体系，支撑高标准数据治理。

02



系统目标与总体架构

点击输入本栏的具体文字简明扼要的说明分项内容
点击输入本栏的具体文字简明扼要的说明分项



系统 目标

构建统一平台：登记、扫描、汇总、报告一体化。

覆盖模态：表格/文本/时序/图像。

四引擎检测：分布偏差/脏数据/对抗脆弱性/物理保真度。

统一调度与可视化报告输出。

预留**Python**算法服务接入能力。

输出可解释化（指标+样本+建议）。



系统总体架构

前端Web UI :

数据集管理、引擎选择、任务启动、报告查看

后端 Go+Gin :

API接口、任务调度、结果汇总；内存DAO/任务模型

Python 算法服务 :

四引擎独立微服务，HTTP接口对接。

数据流 :

前端→后端→算法并行→汇总→前端可视化。

03



关键技术与四引擎算法路线

点击输入本栏的具体文字简明扼要的说明分项内
容点击输入本栏的具体文字简明扼要的说明分项



分布偏差：
频次统计/**KL·JS/PSI/MMD**，输出分布图
与偏差样本

脏数据：
规则校验/重复/置信学习，输出异常和
错标样本



四引擎概览

对抗脆弱性：
FGSM/PGD，输出稳定性与风险等级

物理保真度：
规则/时序/常识约束，输出违规样本
与说明



算法路线（按引擎）：

- 分布偏差：频次统计、**KL/JS**、**PSI**、**MMD**、概念覆盖、分布图。
- 脏数据：**Schema** 校验、规则约束、重复检测、置信学习、图像基础质检。
- 对抗脆弱性：**FGSM/PGD** 探针、扰动前后置信度差、稳定性得分。
- 物理保真度：规则库、时间顺序、单位范围、视觉常识/**VLM** 辅助。

04



已完成成果与系统演示

点击输入本栏的具体文字简明扼要的说明分项内容
点击输入本栏的具体文字简明扼要的说明分项



已完成成果：



南京航空航天大学
NANJING UNIVERSITY OF AERONAUTICS AND ASTRONAUTICS

- **Go+Gin** 后端骨架（入口、路由、配置、依赖注入）。
- 数据集管理 **CRUD** 与前端登记入口。
- 四类引擎元信息与输出字段定义。
- 统一扫描任务接口与状态/结果查询。
- 质量报告结构与查询接口（占位结构已定）。
- 前端单页演示页面。
- **Python** 算法服务 **HTTP Client** 预留



系统演示

05



预期成果与计划（含风险对策）



预期 成果

可运行平台、算法服务集、质量报告、
演示数据集、阶段论文/报告

算法依赖重 -> 先用规则/统计稳定演示；

多模态输入不统一 -> 统一数据结构与报告模板

结果不可解释 -> 输出问题样本+指标+整改建议

耦合风险 -> **Go** 调度 + **Python** 服务解耦

风险 对策



后续计划时间线：



2026.5-6：完善调研+示例数据+联调脚本

2026.6-8：规则/分布统计/标签错误/基础图像质量接入

2026.9-11：图文一致性/对抗/物理一致性完善与可视化

2026.12-2027.4：系统测试+案例分析+结题材料



南京航空航天大学

NANJING UNIVERSITY OF AERONAUTICS AND ASTRONAUTICS

谢谢观看