

多模态数据集质量扫描系统算法论文调研报告

面向初期汇报的算法依据、指标体系与落地路线

项目名称	多模态数据集质量扫描系统
报告定位	算法论文调研与四引擎技术选型
整理日期	2026 年 5 月 10 日
当前系统状态	后端骨架与前端演示页已完成，真实算法服务待接入

一、调研目标

本报告围绕项目已经设计的四类扫描引擎，梳理可支撑初期汇报的代表性论文、算法思想与工程落地方式。调研重点不是堆论文，而是把论文方法转化为可接入后端平台的指标、输入输出和优先级。

- 分布偏差：回答数据集中是否存在类别、概念、模态或采样层面的偏斜。
- 脏数据：回答数据是否存在缺失、重复、格式异常、标签错误和图像基础质量问题。
- 对抗脆弱性：回答样本是否对小扰动敏感，是否可能成为影响模型安全性的风险样本。
- 物理保真度：回答样本是否违反物理规律、时序因果、单位范围和业务逻辑约束。

二、论文到系统的总体映射

引擎	质量维度	主要检测对象	可采用算法/指标	平台输出
分布偏差扫描引擎	分布均衡性	类别比例、长尾覆盖、特征分布漂移、图像颜色/亮度分布、文本词频/主题分布、时序采样频率。	频次统计、KL/JS 散度、PSI、MMD、概念覆盖统计、可视化分布图。	类别/特征分布统计、偏差问题列表、分布图表数据。
脏数据扫描引擎	基础数据质量	缺失值、重复值、格式错误、乱码、标签错误、图像模糊/过曝/截断、字段范围异常。	Schema 校验、规则约束、重复检测、置信学习、基础无参考图像质量评估。	异常统计、疑似标签错误样本、基础质量问题样本列表。
对抗脆弱性扫描引擎	安全性与鲁棒性	对微小扰动高度敏感、预测不稳定、FGSM/PGD 攻击下置信度或类别变化明显的样本。	FGSM 快速探针、PGD 迭代探针、扰动前后置信度差、稳定性得分。	对抗脆弱样本列表、预测稳定性指标、安全风险等级。
物理保真度扫描引擎	物理一致性	图像透视/光照/遮挡不合理，时序因果冲突，表格量纲范围异常，业务逻辑约束冲突。	规则约束、时间顺序检查、单位/范围校验、视觉物理常识检测、VLM 辅助复核。	物理约束违反样本、逻辑/量纲异常统计、风险说明。

三、重点论文与可落地算法

3.1 多模态数据筛选与图文一致性

DataComp 将多模态数据过滤从经验规则推进到可评测的基准流程，说明数据选择本身会显著影响模型能力。对本项目而言，它提示平台不应只做单点异常检测，而应形成“数据统计、质量评分、问题样本定位、过滤建议”的闭环。

CLIPScore 通过图文嵌入相似度衡量图像与文本的一致性，适合在图文数据集质量扫描中识别描述错配、弱相关样本和低语义一致性样本。No Zero-Shot Without Exponential Data 进一步强调概念频率与模型泛化之间的关系，可用于支撑长尾概念覆盖和采样偏差检测。

3.2 分布偏差检测

分布偏差可以先从低成本统计指标入手：类别频次、长尾比例、特征均值/方差、图像亮度/颜色直方图、文本词频与主题分布、时序采样频率。在算法层面，可结合 KL/JS 散度、PSI、MMD 等分布差异度量，把“整体偏斜”和“高风险子集”分开输出。

工程实现建议：第一阶段实现纯统计分布画像；第二阶段接入嵌入模型，将图像、文本样本映射到统一向量空间，再对聚类簇、概念覆盖和离群子集做分析。

3.3 脏数据与标签错误检测

Data Validation for Machine Learning 和 Deequ 的共同启发是：数据质量需要可声明、可复用、可自动执行的约束体系。因此，本项目可把缺失率、重复率、字段范围、格式正则、枚举合法性、跨字段逻辑关系作为规则引擎的基础能力。

Confident Learning 是标签错误检测的核心参考。其思想是利用模型预测置信度估计观测标签与潜在真实标签之间的联合分布，从而定位疑似错标样本。在当前平台中，它可以接入到 `dirty\_data` 引擎，输出疑似标签错误样本、置信度、预测标签和复核建议。

3.4 对抗脆弱性检测

FGSM 提供了低成本的一步梯度扰动探针，适合在平台中做快速扫描；PGD 是更强的迭代式攻击，适用于高风险数据集的深入检测。平台可以记录扰动前后类别变化、置信度下降、最小扰动阈值和稳定性得分，形成安全风险样本列表。

需要注意的是，对抗扫描依赖模型和任务定义。当前后端已经预留 `AlgoClient`，后续 Python 服务应接收数据路径、模型配置、扰动预算和扫描模态，返回统一结构化结果。

3.5 物理保真度与常识一致性

物理保真度不是单一算法问题，而是规则约束、时序逻辑、视觉常识和模型辅助判断的组合。PhyBench 与 BLINK 等工作说明多模态模型在物理感知、空间关系和细粒度视觉判断方面仍存在挑战，因此平台应优先采用“规则检测 + 可解释证据 + 人工复核”的稳健路线。

- 表格/结构化数据：单位、范围、守恒关系、业务逻辑约束和跨字段一致性。
- 时序数据：时间顺序、因果顺序、采样间隔、突变点和不可能状态。
- 图像数据：遮挡关系、透视、光照方向、尺度比例、明显物理异常。

四、算法接入优先级

阶段	优先接入内容	原因	预期输出
第一阶段	规则校验、缺失/重复/格式异常、类别分布统计	实现成本低，能快速把占位结果变成真实扫描结果。	基础质量报告、问题统计、异常样本列表。
第二阶段	Cleanlab 标签错误、CLIPScore 图文一致性、图像基础质量	与多模态数据集质量直接相关，汇报展示效果明显。	疑似错标、图文错配、低质量图片样本。
第三阶段	FGSM/PGD 脆弱性探针、嵌入分布偏差、物理规则库	需要模型、任务和数据集适配，适合在平台稳定后接入。	鲁棒性风险、长尾覆盖、物理约束问题。

五、与当前代码的对接建议

- 1. 保持 Go 后端负责数据集登记、任务调度、结果存储、报告汇总和前端展示。
- 2. 新建 Python 算法服务，按 `/scan/distribution-bias`、`/scan/dirty-data`、`/scan/adversarial-vulnerability`、`/scan/physical-fidelity`` 暴露接口。
- 3. 每个算法服务统一返回 `score`、`metrics`、`issue_types`、`sample_issues`、`charts`、`recommendations`，直接映射到当前 `scan.Result`` 结构。
- 4. 第一批算法以可解释、稳定、容易演示为主，优先避免依赖过重模型导致初期展示不稳定。

参考文献与资料来源

[1] **DataComp: In search of the next generation of multimodal datasets.** 提供面向图文数据的大规模数据过滤与评测框架，可作为本项目多模态质量指标体系的参考。 <https://arxiv.org/abs/2304.14108>

[2] **CLIPScore: A Reference-free Evaluation Metric for Image Captioning.** 利用图像-文本表征相似度评估图文匹配程度，可用于发现图文样本错配、弱相关和低质量描述。 <https://arxiv.org/abs/2104.08718>

[3] **No Zero-Shot Without Exponential Data.** 说明预训练数据中的概念频率与泛化能力相关，提示需要检测长尾类别、概念覆盖和采样偏差。 <https://arxiv.org/abs/2404.04125>

[4] **Data Validation for Machine Learning.** 提出训练数据的 schema、统计特征、漂移和异常监控方法，适合作为脏数据规则引擎基础。 <https://research.google/pubs/data-validation-for-machine-learning/>

[5] **Automating Large-Scale Data Quality Verification.** Deequ 论文强调通过约束、统计分析和自动化验证保障数据管道质量。 <https://www.vldb.org/pvldb/vol11/p1781-schelter.pdf>

[6] **Confident Learning: Estimating Uncertainty in Dataset Labels.** 通过置信学习估计观测标签与潜在真实标签的联合分布，用于自动发现疑似标签错误。 <https://arxiv.org/abs/1911.00068>

- [7] **Pervasive Label Errors in Test Sets Destabilize Machine Learning Benchmarks.** 指出测试集标签错误会显著影响基准排序，支撑本项目纳入标签质量检测。 <https://arxiv.org/abs/2103.14749>
- [8] **Explaining and Harnessing Adversarial Examples.** 提出 FGSM 快速梯度符号攻击，可作为对抗脆弱性扫描的轻量探针。 <https://arxiv.org/abs/1412.6572>
- [9] **Towards Deep Learning Models Resistant to Adversarial Attacks.** 提出以 PGD 为代表的强对抗攻击与鲁棒训练视角，可用于敏感样本筛查。 <https://arxiv.org/abs/1706.06083>
- [10] **PhyBench: Holistic Evaluation of Physical Perception and Reasoning.** 提供多模态物理感知与推理评测思路，可映射到物理保真度扫描中的视觉与常识约束。 <https://arxiv.org/abs/2406.11802>
- [11] **BLINK: Multimodal Large Language Models Can See but Not Perceive.** 强调视觉感知细节、空间关系和细粒度判断能力，可作为视觉物理一致性检查的补充参考。 <https://arxiv.org/abs/2404.12390>